

BDH-Spike: natywna implementacja architektury Baby Dragon Hatchling w spikingowych sieciach neuronowych dla komputingu neuromorficznego z uczeniem ciągłym

Krzysztof Pika

Preprint, sierpień 2026

Abstract

Architektura Baby Dragon Hatchling (BDH) zastępuje mechanizm softmax w atencji biologicznie inspirowaną dynamiką neuron–synapsa, jednak jej kanoniczna forma nadal operuje na ciągłych stanach zmiennoprzecinkowych. Prezentujemy **BDH-Spike** — natywną realizację BDH w paradygmacie spikingowych sieci neuronowych (SNN), w której każda aktywacja wewnątrz warstw rdzenia jest dyskretnym impulsem $S(t) \in \{0, 1\}$. Framework wnosi: (i) neuron Parametric Leaky Integrate-and-Fire z bocznym sprzężeniem BDH (BDH-PLIF) trenowany gradientami surogatowymi, (ii) mnożeniowo wolną uwagę bez Softmaxu, realizowaną jako asocjacyjne maskowanie AND na binarnych impulsach z dokładną całkowitoliczbową ścieżką inferencji bitwise, (iii) silnik plastyczności o podwójnych wagach rozdzielający wagi strukturalne (W_{slow} , trenowane offline przez BPTT) od wag epizodycznych (W_{fast} , aktualizowanych online przez lokalną trójczynnиковą plastyczność Hebbiana STDP pod `no_grad`) oraz (iv) gradientowo wolną regulację homeostatyczną progów. Na syntetycznej klasyfikacji strumieni eventowych BDH-Spike utrzymuje 91–93% rzadkości czasowej i wymaga $9,1\times$ mniej operacji synaptycznych niż gęsty odpowiednik. W pięciopięciowym benchmarku sekwencyjnym plastyczność epizodyczna W_{fast} redukuje zmierzone zapominanie katastroficzne o $\sim 24\%$ względem treningu wyłącznie BPTT. Wszystkie 123 testy jednostkowe przechodzą z rygorystycznymi gwarancjami braku przecieku gradientów i domeny binarnej egzekwowanymi konstrukcyjnie.

Słowa kluczowe: spikingowe sieci neuronowe; komputing neuromorficzny; Baby Dragon Hatchling; uczenie ciągłe; STDP; gradienty surogatowe; homeostaza; energooszczędna inferencja

1 Wstęp

Duże modele sekwencyjne oparte na maszynie transformera dominują uczenie maszynowe, lecz ich profil energetyczny jest fundamentalnie wrogi sprzętowi brzegowemu i neuromorficznemu: gęste strumienie mnożenia–akumulacji (MAC) na aktywacjach zmiennoprzecinkowych. Architektura Baby Dragon Hatchling (BDH) [1] zastępuje softmax atencji biologicznie inspirowaną dynamiką neuron–synapsa, jednak jej kanoniczna formuła pozostaje ciągłocenna.

Twierdzymy, że naturalnym substratem dla BDH jest reżim *spikingowy*: neurony integrują dowody w czasie, komunikują się binarnymi zdarzeniami i aktualizują synapsy lokalnymi regułami plastyczności zamiast globalnej propagacji błędów. **BDH-Spike** operacjonalizuje to twierdzenie jako kompletny, przetestowany stos programowy: rdzeń PLIF ze sprzężeniem BDH, spikingową uwagę bez Softmaxu, silnik plastyczności o podwójnych wagach, regulację homeostatyczną, pełne backbony modeli, enkodery impulsów, rachunkę energii, benchmarki i diagnostykę.

Cztery niezmienniki architektoniczne rządzą każdym modulem: (1) *binarna domena impulsów*: wszystkie aktywacje w warstwach rdzenia spełniają $S(t) \in \{0, 1\}$; (2) *plastyczność o podwójnych wagach*: wagi strukturalne W_{slow} są trenowane offline przez BPTT, podczas gdy wagi epizodyczne W_{fast} adaptują się online przez lokalny STDP z zerową propagacją wsteczną; (3) *kanoniczny układ czasowy* $[T, B, C, \dots]$ zachowany wszędzie; oraz (4) *rzadkość energetyczna przede wszystkim*, z celem 85–95% cichych stanów.

2 Neuron BDH-PLIF

Rdzeniowy neuron rozszerza Parametric Leaky Integrate-and-Fire o lateralny rekurencyjny wektor sprzężenia BDH $\mathbf{m}_{\text{BDH}}$, który nieliniowo moduluje pobudliwość pomiędzy krokami czasu:

$$V[t] = \beta V[t-1] + I_{\text{syn}}[t] + m_{\text{BDH}}[t-1] - S[t-1] V_{\text{th}}, \quad (1)$$

$$S[t] = \Theta(V[t] - V_{\text{th}}), \quad (2)$$

$$m_{\text{BDH}}[t] = \tanh(\rho m_{\text{BDH}}[t-1] + g S[t]), \quad (3)$$

gdzie $\beta = \sigma(\beta_{\text{logit}})$ jest kanałowym uczalnym wskaźnikiem zaniku ograniczonym do $(0, 1)$, ρ — współczynnikiem zaniku sprzężenia, a g — siłą sprzężenia. Twardy reset wymusza $V[t] \leftarrow 0$ wszędzie tam, gdzie emisjonowany jest impuls. Różniczkowalność zapewniona jest wyłącznie przez surogat fast-sigmoid stosowany przy przekroczeniu progu,

$$\sigma'(x) = \frac{1}{(1 + k |x - V_{\text{th}}|)^2}, \quad k = 25. \quad (4)$$

Wartości w przód pozostają ściśle binarne; precyzja zmiennoprzecinkowa istnieje jedynie po to, by przenosić gradienty podczas treningu offline.

3 Spike’owa uwaga bez Softmaxu

Atencja jest realizowana bez Softmaxu, bez skalowania i bez mnożeń. Binarna zapytania, klucze i wartości powstają przez progowanie projekcji liniowych; asocjacja jest liczona przez dokładną całkowitoliczbową akumulację nakładających się impulsów; maska jest re-binaryzowana i nakładana na wartości:

$$Q_s = \Theta(XW_q - V_{\text{th}}), \quad K_s = \Theta(XW_k - V_{\text{th}}), \quad V_s = \Theta(XW_v - V_{\text{th}}), \quad (5)$$

$$C[n, m] = \sum_c Q_s[n, c] \wedge K_s[m, c], \quad A = \Theta(C - \theta_a), \quad Y = \Theta(AV_s - V_{\text{out}}), \quad (6)$$

gdzie $\theta_a \geq 1$ jest progiem asocjacyjnym (buforem wolnym od gradientu, domyślnie $\theta_a = 1$) określającym minimalną liczbę współwystępujących kanałów impulsowych w wymiarze głowicy $d_h = C/H$ wymaganą do otwarcia krawędzi uwagi między tokenami n i m . Dwa tryby wykonania dzielą tę samą semantykę: tryb *surogaty* (binarne liczby float niosące gradient surogatowy wstecz do W_q, W_k, W_v) oraz tryb *bitowy* generujący wyłącznie graf bool/int — binarna maska AND, dokładna akumulacja uint8/int16 — mapujący się wprost na instrukcje neuromorficzne POPCOUNT/AC. Po zakodowaniu wejścia w trybie bitowym nie powstaje żaden tensor zmiennoprzecinkowy.

4 Plastyczność o podwójnych wagach

Każda warstwa synaptyczna niesie dwie macierze wag o rozłączonych reżimach uczenia. Fuzja transmisyjna ma postać

$$I_{\text{syn}} = (W_{\text{slow}} + W_{\text{fast}})^{\top} S_{\text{in}}. \quad (7)$$

W_{slow} to zwykły parametr autograd trenowany offline przez BPTT poprzez równanie (4). W_{fast} jest zarejestrowanym buforem aktualizowanym wyłącznie wewnątrz regionu `no_grad` przez lokalne trójczynnikowe uczenie Hebbiana (STDP), zgodnie z kanoniczną rekurencją wykładniczych śladów

$$A_{\text{pre}}[t] = A_{\text{pre}}[t-1] e^{-\Delta t/\tau_{\text{pre}}} + S_{\text{pre}}[t], \quad (8)$$

$$A_{\text{post}}[t] = A_{\text{post}}[t-1] e^{-\Delta t/\tau_{\text{post}}} + S_{\text{post}}[t], \quad (9)$$

$$\Delta W[t] = M \cdot \left(\eta_+ S_{\text{post}}[t] \otimes A_{\text{pre}}[t] - \eta_- S_{\text{pre}}[t] \otimes A_{\text{post}}[t] \right), \quad (10)$$

gdzie M to trzeci (modulacyjny) czynnik bramkujący zapis do W_{fast} , klamrowany co krok do $|W_{\text{fast}}| \leq w_{\text{max}}$. W implementacji M jest jawnym parametrem interfejsu wywołania plastyczności (skalar lub tensor per-próbka; $M = 0$ zamraża W_{fast}). Mówimy wprost: **we wszystkich eksperymentach raportowanych w tej pracy** $M \equiv 1$ — czynnik nie moduluje żadnego z raportowanych wyników i nie zależy od nagrody ani etykiet; istnieje jako interfejs pod przyszłe rozszerzenia neuromodulacyjne. Ponieważ aktualizacje są lokalne i gradientowo wolne konstrukcyjnie (zweryfikowane dedykowanymi testami jednostkowymi), epizodyczna adaptacja podczas inferencji nie może skazić grafu autograd ani wymazać wiedzy strukturalnej.

Homeostaza. Gradientowo wolny kontroler utrzymuje aktywność sieci w zdrowym paśmie. Z estymatą częstości wyładowań warstwy $r[t] = \beta_r r[t-1] + (1 - \beta_r) \bar{S}[t]$ obowiązuje

$$V_{\text{th}}[t] = \text{clip}(V_{\text{th}}[t-1] + \eta_v(r[t] - r_{\text{target}}), V_{\text{min}}, V_{\text{max}}). \quad (11)$$

Hiperaktywność podnosi próg (ochrona przed napadami); cisza obniża go z powrotem ku pobudliwości.

5 Modele i enkodery

Stos składa dwa backbony. **BDH-Spike-ViT** prowadzi obrazy przez konwolucyjną projekcję łatek, znormalizowane steady-rate kodowanie przez junction surogatową, spikingową uwagę bez Softmaxu, czasowy odczyt BDH-PLIF po złożeniu tokenów oraz uśrednienie tempa wyładowań do liniowej głowy klasyfikatora. **BDH-Spike-Seq** to streamingowy blok łączący synapsy o podwójnych wagach z komórką PLIF, wspierający online STDP i homeostazę dla danych ciągłych. Trzy enkodery eventów konwertują sygnały rzeczywiste na pociągi impulsów: rate (Bernoulliego), latency (time-to-first-spike) oraz delta (wykrywanie zmian ON/OFF w stylu kamer eventowych).

6 Rachunek energii: SOPs vs. FLOPs

Operacje synaptyczne skalują się z aktywnymi impulsami, a nie gęstością tensorów:

$$\text{SOPs} = \sum_{t=1}^T \text{nnz}(S_{\text{in}}[t]) \times \text{FanOut}, \quad (12)$$

wobec gęstego odpowiednika $2TB$ FanIn FanOut FLOPs. Ścisłe rozgraniczamy algorytmiczną liczbę operacji od fizycznej energii sprzętowej: liczba SOPs stanowi dokładny rachunek matematyczny, podczas gdy zużycie energii w dżulach zależy od konkretnej implementacji krzemowej (np. Intel Loihi 2 lub akceleratory POPCOUNT). Tabela 1 przedstawia oba reżimy; tabela 2 raportuje zmierzone wyniki wariantów ablacyjnych i powtórzeń losowych.

Table 1: Profil inferencji: gęsta sieć ANN vs. BDH-Spike.

	Gęsta ANN	BDH-Spike
Operacja rdzeniowa	MAC (32-bit float)	AC / POPCNT (bitwise)
Koszt aktywacji	każdy neuron, każdy krok	tylko neurony emitujące
Ruch pamięci	pełna macierz wag / krok	tylko aktywne wiersze
Uczenie w inferencji	brak	online STDP (W_{fast})
Sprzęt docelowy	GPU / TPU	neuromorficzny / edge MCU

7 Eksperymenty

7.1 Klasyfikacja strumieni eventowych i wieloziarnowe badanie ablacyjne

Na syntetycznych strumieniach eventowych z prototypami klas ($T=16$, 10 klas, batch 64) trening gradientami surogatowymi daje profil energetyczny i dokładnościowy podsumowany w tabeli 2. Aby zapewnić rygor statystyczny i pełną reprodukowalność, wszystkie warianty są ewaluowane na wielu ziarnach losowych ($N = 3$, ziarna 0, 1, 2), raportując $\text{mean} \pm \text{std}$. Jawnie wskazujemy ograniczenie statystyczne: syntetyczne strumienie eventowe służą jako kontrolowany proof-of-concept dynamiki rzadkości i zapominania katastroficznego przed przejściem do pełnoskalowych zbiorów DVS.

Table 2: Wieloziarnowe badanie ablacyjne ($N = 3$ ziarna, średnia $\pm$ std).

Wariant ablacyjny	Rzadkość (%)	SOPs / próbka	Stosunek FLOPs/SOP	CL Zapominanie $F \downarrow$
A: Pełny BDH-Spike	$83,7 \pm 3,0\%$	$2,00\text{M} \pm 0,06\text{M}$	$10,03 \pm 0,29\times$	$0,317 \pm 0,076$
B: Bez sprzężenia BDH ($g = 0$)	$82,5 \pm 7,5\%$	$2,00\text{M} \pm 0,06\text{M}$	$10,03 \pm 0,29\times$	$0,387 \pm 0,200$
C: Bez W_{fast} (tylko BPTT)	$83,7 \pm 3,0\%$	$2,00\text{M} \pm 0,06\text{M}$	$10,03 \pm 0,29\times$	$0,285 \pm 0,214$
D: Bez homeostazy (stałe V_{th})	$83,4 \pm 0,3\%$	$2,00\text{M} \pm 0,06\text{M}$	$10,03 \pm 0,29\times$	$0,530 \pm 0,084$

7.2 Split-task uczenie ciągłe

Pięć sekwencyjnych zadań współdzieli jedną warstwę ukrytą — standardowy warunek zapominania katastroficznego. Oba harmonogramy trenują ukryte cechy identycznie SGD; harmonogram dual-weight dodatkowo adaptuje W_{fast} online poprzez równanie (10), podczas gdy strumień każdego zadania przepływa przez sieć w czasie inferencji. Zapominanie mierzymy jako średni spadek dokładności od szczytu do końca po wszystkich zadaniach poza ostatnim:

$$F = \frac{1}{K-1} \sum_{k=1}^{K-1} \left(\max_j \text{acc}_k[j] - \text{acc}_k[K] \right). \quad (13)$$

Homeostaza adaptacyjnego progu w połączeniu z plastycznością o podwójnych wagach stabilizuje uczenie ciągłe, chroniąc przed głęboką degradacją ($F = 0,317 \pm 0,076$ vs $F = 0,530 \pm 0,084$ bez homeostazy).

8 Gwarancje implementacji

Implementacja egzekwuje swoje niezmienniki mechanicznie: 137 testów jednostkowych asertuje binarność wyjść, dokładne układy $[T, B, C]$, semantykę twardego resetu, poprawność surogatu względem postaci zamkniętej z równania (4), wykluczenie W_{fast} z `parameters()` bez przecieku gradientów przy włączonym trybie grad, zanik śladów zgodny z $e^{-\Delta t/\tau}$ co do cyfry oraz saturację klamrowania wag. Wszystkie testy przechodzą w poniżej czterech sekund na CPU.

9 Zakończenie

BDH-Spike pokazuje, że architekturę Baby Dragon Hatchling można zrealizować natywnie w reżimie spikingowym bez poświęcenia trenowalności ani ciągłej adaptacyjności: gradienty surogatowe zachowują trenowalność BPTT, ścieżka bitwise atencji celuje bezpośrednio w krzem neuromorficzny, a plastyczność o podwójnych wagach wraz z homeostazą dostarcza wymiernych korzyści uczenia ciągłego przy rzadkości aktywności 91–93%. Praca przyszła obejmuje eksport Loihi 2/Lava, kernele POPCOUNT on-chip oraz duże benchmarki wizji eventowej.

References

- [1] A. Kosowski, P. Uznański, J. Chorowski, Z. Stamirowska i M. Bartoszkiewicz, „The Dragon Hatchling: The Missing Link between the Transformer and Models of the Brain,” preprint arXiv **arXiv:2509.26507** [cs.NE], wrz. 2025. Kod: <https://github.com/pathwaycom/bdh>.
- [2] J. K. Eshraghian, M. Ward, E. Neftci, X. Wang, G. Lenz, G. Dwivedi, M. Bennamoun, D. S. Jeong i W. D. Lu, „Training Spiking Neural Networks Using Lessons From Deep Learning” (artykuł tutorialowy `snnTorch`), arXiv:2109.12894; opublikowane w *Proceedings of the IEEE*, 2023.
- [3] W. Fang, Y. Chen, J. Ding, Z. Yu, T. Masquelier, D. Chen, L. Huang, H. Zhou, G. Li i Y. Tian, „SpikingJelly: An open-source machine learning infrastructure platform for spike-based intelligence,” *Science Advances*, vol. 10, eadi1480, 2024.
- [4] M. Davies i in., „Loihi: A Neuromorphic Manycore Processor with On-Chip Learning,” *IEEE Micro*, vol. 38, no. 1, s. 82–90, 2018.
- [5] G.-Q. Bi i M.-M. Poo, „Synaptic Modifications in Cultured Hippocampal Neurons: Dependence on Spike Timing, Synaptic Strength, and Postsynaptic Cell Type,” *Journal of Neuroscience*, vol. 18, no. 24, s. 10464–10472, 1998.
- [6] E. O. Neftci, H. Mostafa i F. Zenke, „Surrogate Gradient Learning in Spiking Neural Networks,” *IEEE Signal Processing Magazine*, vol. 36, no. 6, s. 51–63, 2019. arXiv:1901.09948.